

Závěrečný projekt v SQL

Datová analýza ve finančním sektoru

V naší další práci budeme využívat [finanční](#) databázi, která obsahuje informace o úvěrech (ať už plně splacených, či nikoli).


Za zmínku stojí, že databáze používá reálná data, která byla anonymizována za účelem zveřejnění. Jedná se o sbírku finančních informací z české banky. Datová sada obsahuje data pro více než 5 300 klientů s přibližně milionem transakcí. Banka navíc zveřejnila data pro téměř 700 poskytnutých úvěrů a přibližně 900 vydaných kreditních karet.

Struktura databáze

Seznamte se se schématem databáze a odpovězte na následující otázky:

1. Jaké jsou primární klíče v jednotlivých tabulkách?
2. Jaké vztahy mají jednotlivé dvojice tabulek?

Schéma



Popis tabulek

Karta

Tabulka obsahuje údaje o kreditních kartách

Sloupce:

- **card_id**- identifikační číslo karty,
- **disp_id**- identifikační číslo držitele karty,
- **type**- typ karty (klasická, zlatá atd.),
- **issued**- datum vydání karty.

Disp

Tabulka obsahuje informace o osobách přiřazených ke kartě. Její název je zkratkou termínu: disponent a označuje osobu, která může kartu také používat.

Sloupce:

- **disp_id**- identifikační číslo držitele karty,
- **client_id**- ID klienta,
- **account_id**- ID účtu, ke kterému je karta přiřazena,
- **type**- typ správy karty (majitel nebo disponent).

Klient

Tabulka obsahuje základní informace o klientovi.

Sloupce:

- **client_id**- ID klienta,
- **gender**- pohlaví klienta,
- **birth_date**- datum narození klienta,
- **district_id**- identifikační číslo oblasti bydliště klienta.

Okres,

Tabulka obsahuje demografické údaje pro danou oblast.

Sloupce:

- **district_id**- identifikační číslo okresu,
- **A2**- název okresu,
- **A3**- region,
- **A4**- počet obyvatel,
- **A5**- počet obcí s méně než 499 obyvateli,
- **A6**- počet obcí s 500–1999 obyvateli,
- **A7**- počet obcí s 2000–9999 obyvateli,
- **A8**- počet obcí s více než 10 000 obyvateli,
- **A9**- počet měst,
- **A10**- poměr obyvatel městských a venkovských oblastí,
- **A11**- průměrný plat,
- **A12**- míra nezaměstnanosti v roce 1995,
- **A13**- míra nezaměstnanosti v roce 1996,
- **A14**- počet podnikatelů na 1000 obyvatel,
- **A15**- počet trestných činů spáchaných v roce 1995,
- **A16**- počet trestných činů spáchaných v roce 1996,

Účet

Tabulka obsahuje informace o účtech.

Sloupce:

- **account_id**- ID účtu,
- **district_id**- identifikační číslo okresu s pobočkou, která účet otevřela,
- **frequency**- četnost vydávání výpisů,
- **date**- datum otevření účtu.

Trans

Tabulka obsahuje informace o transakcích

Sloupce:

- **trans_id**- identifikační číslo transakce,
- **account_id**- ID účtu, ke kterému je transakce přiřazena,
- **date**- datum transakce,
- **type**- debetní/kreditní transakce,
- **operation**- druh transakce,
- **amount**- výše transakce,
- **balance**- zůstatek na účtu po transakci,
- **k_symbol**- charakteristiky transakce,
- **bank**- banka transakčního partnera,
- **account**- účet transakčního partnera.

Objednávka

Tabulka obsahuje charakteristiky platebního příkazu.

Sloupec:

- **order_id**- identifikátor,
- **account_id**- ID účtu,
- **bank_to**- ID banky příjemce,
- **account_to**- ID účtu příjemce,
- **amount**- částka převodu,
- **k_symbol**- platební charakteristika.

Půjčka

Tabulka obsahuje informace o stavu úvěru.

Sloupce:

- **loan_id**- identifikační číslo půjčky,
- **account_id**- identifikační číslo účtu žadatele o úvěr,
- **date**- údaje o poskytnutí půjčky,
- **amount**- výše úvěru,
- **duration**- doba trvání úvěru,
- **payments**- výše měsíční splátky,
- **status**- stav splácení úvěru.

Zadání č. 1

Historie poskytnutých úvěrů

Napište dotaz, který připraví souhrn poskytnutých úvěrů v následujících dimenzích:

- rok, čtvrtletí, měsíc,
- rok, čtvrtletí,
- rok,
- celkový.

Jako výsledek shrnutí zobrazte následující informace:

- celková výše úvěrů,
- průměrná výše úvěru,
- celkový počet poskytnutých půjček.

Zadání č. 2

Stav úvěru

Na webu databáze můžeme najít informaci, že v databázi je celkem 682 udělených úvěrů, z nichž 606 bylo splaceno a 76 ne.

Předpokládejme, že nemáme informace o tom, který stav odpovídá splacené půjčce a který ne. V této situaci musíme tuto informaci odvodit z dat.

Chcete-li to provést, napište dotaz, který vám pomůže odpovědět na otázku, které stavy představují splacené půjčky a které nesplacené půjčky.

Zadání č. 3

Analýza účtů

Napište dotaz, který seřadí účty podle následujících kritérií:

- počet poskytnutých půjček (klesající),
- objem poskytnutých úvěrů (klesající),
- průměrná výše úvěru,

Zohledňují se pouze **plně splacené půjčky**.

Zadání č. 4

Plně splacené půjčky

Zjistěte zůstatek splacených úvěrů dělený podle pohlaví klienta.

Dále použijte metodu dle vlastního výběru k ověření, zda je dotaz správný.

Zadání č. 5

Analýza klienta - 1. část

Upravte dotazy z cvičení o splacených úvěrech a odpovězte na následující otázky:

- Kdo má více splacených půjček - ženy nebo muži?
- Jaký je průměrný věk dlužníka dělený podle pohlaví?

Tipy:

- Výsledek dříve napsaného a následně upraveného dotazu uložte například do dočasné tabulky a proveďte na ní analýzu.
- Věk můžete vypočítat jako rozdíl: 2024 - rok narození dlužníka.

Zadání č. 6

Analýza klienta - 2. část

Proveďte analýzy, které odpoví na otázky:

- která oblast má nejvíce klientů,
- ve které oblasti byl splacen nejvyšší počet půjček,
- ve které oblasti byla vyplacena nejvyšší částka půjček.

Jako klienty vyberte pouze **vlastníky** účtů.

Zadání č. 7

Analýza klienta - 3. část

Použijte dotaz vytvořený v předchozím úkolu a upravte ho tak, aby určoval procentuální podíl každého okresu na celkovém objemu poskytnutých úvěrů.

Výsledek vzorku:

okres_id	částka_zákazníka	výše_půjček	počet_půjček	podíl_amount
1	73	100	2	0,6666
74	17 let	50	5	0,3333

Jinými slovy, úkolem je určit rozložení poskytnutých úvěrů podle regionů.

Zadání č. 8

Výběr - 1. část

Výběr klienta

Zkontrolujte v databázi klienty, kteří splňují následující výsledky:

- zůstatek na jejich účtu je vyšší než 1000,
- mají více než 5 půjček,
- narodili se po roce 1990.

A předpokládáme, že zůstatek na účtu je **loan amount- payments**.

Zadání č. 9

Výběr, část 2

Z předchozího cvičení pravděpodobně již víte, že neexistují žádní zákazníci, kteří by splňovali požadavky. Proveďte analýzu, abyste zjistili, která podmínka způsobila prázdné výsledky.